

QUY TẮC OCR/POST-OCR CHO HEADING VÀ LIST ITEM

Tài liệu chốt để chuẩn hóa Markdown trước khi đưa vào pipeline chunking và embedding

Mục tiêu: OCR tạo Markdown có cấu trúc đủ chính xác để backend chỉ cần phân loại block và chunk, không phải sửa lại heading đã nhận sai.

1. Nguyên tắc cốt lõi

- Chỉ thêm # ## ### khi dòng được xác định rõ là tiêu đề section.
- Các mục liệt kê không được gắn heading; chúng phải giữ nguyên marker để backend tạo child chunk.
- Khi không chắc chắn, ưu tiên giữ là item. Precision quan trọng hơn recall.
- Không sửa hoặc làm mất nội dung OCR gốc; nên lưu riêng raw OCR và canonical Markdown.

2. Bảng quyết định OCR/Post-OCR

Dạng dòng	Mặc định	Điều kiện/ghi chú
#, ##, ### ...	Heading	Chỉ dùng cho tiêu đề section rõ ràng.
1) 2) 3)	numbered_item	Trong dataset hiện tại chưa có trường hợp 1) là heading thật.
a) b) c)	lettered_item	Không gắn #.
a/ b/ c/	lettered_item	Không gắn #.
A) B) C)	lettered_item	Mặc định là item; chỉ ngoại lệ khi tài liệu thể hiện section rất rõ.
A/ B/ C/	lettered_item	Mặc định là item.
1. 2. 3.	Xét ngữ cảnh	Heading nếu ngắn, giống tên mục, có body riêng; item nếu là câu hoàn chỉnh.
1/ 2/ 3/	Xét ngữ cảnh	Có thể là heading con hoặc item tùy cấu trúc.
A. B. C.	Candidate heading	Heading nếu ngắn, có sibling cùng cấp và có body riêng; ngược lại là item.
a. b. c.	lettered_item	Mặc định là item; chỉ nâng thành heading khi bằng chứng rất rõ.

3. Cách phân biệt heading và item với dạng mơ hồ

Xem là heading khi có nhiều tín hiệu sau:

- Dòng ngắn, giống tên section hoặc cụm danh từ.
- Không phải câu văn/quy định dài; thường không kết thúc bằng dấu “.” hoặc “;”.
- Có các sibling cùng cấp: 1., 2., 3. hoặc A., B., C.
- Có paragraph, bảng hoặc danh sách nội dung nằm bên dưới.
- Thường in hoa, in đậm hoặc nằm dưới một heading lớn hơn.

Xem là item khi có một hoặc nhiều tín hiệu sau:

- Là câu hoàn chỉnh, nội dung dài hoặc mang tính quy định.
- Kết thúc bằng dấu “.” hoặc “;”.
- Nằm trong chuỗi liệt kê sau các nhãn như “Lưu ý”, “Bao gồm”, “Cụ thể”, “Hồ sơ gồm”.
- Không có body riêng bên dưới.

4. Ví dụ đúng và sai

SAI	ĐÚNG
### 1) Không áp dụng chế độ miễn, giảm học phí... ### 2) Các đối tượng thuộc diện...	1) Không áp dụng chế độ miễn, giảm học phí... 2) Các đối tượng thuộc diện...
### a. Sinh viên phải nộp hồ sơ... ### b. Hồ sơ phải đầy đủ...	a. Sinh viên phải nộp hồ sơ... b. Hồ sơ phải đầy đủ...
1. MỤC ĐÍCH → luôn coi là item	### 1. MỤC ĐÍCH (khi đây là tên mục có body riêng)

5. Output canonical Markdown mong muốn

```
## Hướng dẫn sinh viên
1/ Những điều sinh viên cần biết...
2/ Ký túc xá sinh viên...
Lưu ý:
1) Không áp dụng chế độ miễn, giảm học phí...
2) Các đối tượng thuộc diện miễn, giảm học phí...
```

6. Contract giữa OCR và backend

OCR/Post-OCR	Backend chunking
Xuất Markdown đúng cấu trúc.	# # # # # → heading → tạo parent.
Không gắn # cho list item.	1. 1) 1/ → numbered_item → atomic child.
Giữ nguyên marker và nội dung.	a. a) a/ → lettered_item → atomic child.
Giữ page marker, table và code block.	Paragraph sau item được gắn vào item hiện tại.

7. Thứ tự nhận diện bắt buộc

Page marker → Fenced code block → Markdown table → Heading thật → Numbered item → Lettered item → Paragraph

Quyết định cuối: OCR chỉ thêm heading khi đủ chắc chắn. Dạng 1), a), A), a/, A/ mặc định là item. Dạng 1., 1/, A. cần xét ngữ cảnh. Khi không chắc chắn, giữ là item để tránh tạo sai cấu trúc parent-child.